

8. Análisis de Intervención y observaciones atípicas.

8.1 Análisis de intervención

- Las series de tiempo están frecuentemente afectadas por eventos tales como días de fiesta, huelgas, promociones, apagones, y otros, como cambios de política.
- Cuando el momento de ocurrencia de estos eventos externos (exógenos) es conocido, se les llama *intervenciones*. Box y Tiao (1975) desarrollaron el **Análisis de Intervención** para estudiar los cambios estructurales sobre las series de tiempo debido a esta clase de eventos.
- Hay dos tipos de variables que son empleadas para modelar una intervención:

$$\begin{aligned} \text{- La función de salto } S_t(T) &= 0 \text{ si } t < T \\ &= 1 \text{ si } t \geq T \end{aligned}$$

Esta variable sirve para representar una intervención que ocurre en el período T y permanece de ahí en adelante.

$$\begin{aligned} \text{- La función de pulso } P_t(T) &= 1 \text{ si } t = T \\ &= 0 \text{ si } t \neq T \end{aligned}$$

Esta variable sirve para representar una intervención que ocurre solamente en el período T.

- Relación entre $S_t(T)$ y $P_t(T)$: $P_t(T) = (1-B)S_t(T)$.

- Hay muchas posibles respuestas (modelos) para las funciones de salto y de pulso. Por ejemplo,

i) Para modelar el efecto de un impacto fijo desconocido sentido después de b períodos que ocurrió la intervención:

$wB^bS_t(T)$: el impacto fijo (o efecto) es w y permanece en el sistema desde el período $T+b$

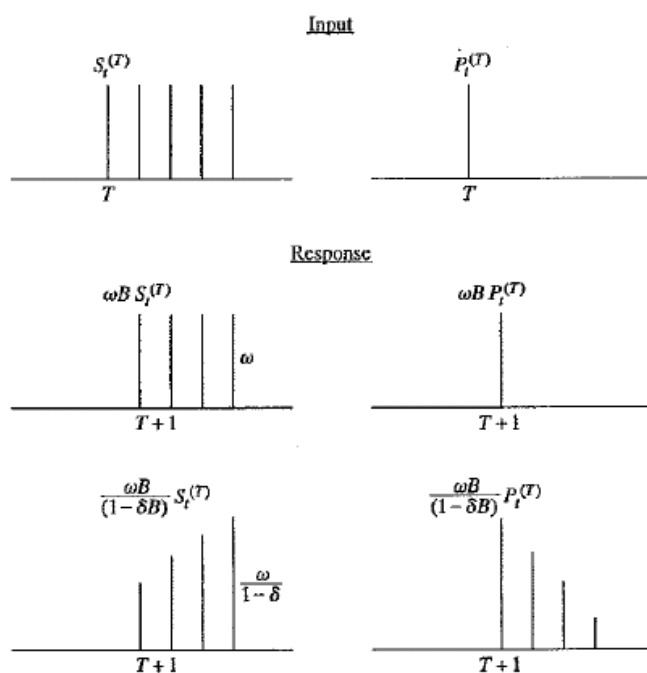
$wB^bP_t(T)$: el impacto fijo es w y dura sólo en el período $T+b$

ii) El impacto de la intervención se siente b períodos después, pero la respuesta es gradual:

$\frac{w}{1-\delta B}B^bS_t(T)$: el impacto inicial en el período $T+b$ es w y se incrementa permanentemente a una tasa δ , $0 \leq \delta \leq 1$.

$\frac{w}{1-\delta B}B^bP_t(T)$: el impacto inicial en el período $T+b$ es w y disminuye permanentemente a una tasa δ , $0 \leq \delta \leq 1$.


Respuestas a las variables de entrada de salto y pulso.



iii) Varias respuestas pueden ser producidas combinando funciones de salto y pulso:

$$\frac{\omega_0}{1-\delta B} B P_t(T) + \omega_1 B S_t(T)$$

con $0 < \delta < 1$. Este modelo es útil para representar un fenómeno en el cual una intervención produce una respuesta que decrece gradualmente pero deja un efecto residual permanente en el sistema. El siguiente gráfico ilustra el comportamiento de este tipo de intervención.



iv) En forma general la respuesta a una intervención puede ser representada por la función racional:

$$v(B) = \frac{w(B)}{\delta(B)} B^b$$

donde $w(B) = w_0 - w_1B - w_2B^2 - \dots - w_sB^s$, y $\delta(B) = 1 - \delta_1B - \delta_2B^2 - \dots - \delta_rB^r$, son polinomios en B, y b es el tiempo de retraso que toma la intervención para tener efecto; los coeficientes w_j generalmente representan los valores esperados iniciales de la intervención.

Se asume que las raíces de $\delta(B)=0$ están sobre o fuera del círculo unidad.

Una raíz unitaria en este polinomio indica un impacto que **incrementa linealmente**, y una raíz fuera del círculo unidad representa un fenómeno que tiene una **respuesta que decrece o crece gradualmente**.

Las funciones de intervención $v(B)$ también son llamadas las **funciones de transferencia del impacto**.

- Especificación de un modelo ARIMA(p,d,q) con k intervenciones.

Para una serie con múltiples intervenciones, definimos la clase general de modelos:


$$Z_t = \sum_{j=1}^k \frac{w_j(B)}{\delta_j(B)} B^{b_j} I_{jt} + \frac{\theta(B)}{\psi(B)} a_t$$

donde I_{jt} , $j=1,2,\dots,k$ son variables de intervención de salto o pulso y $\psi(B) = (1-B)^d \phi(B)$.

- La forma (modelo) de la intervención se postula basados en la forma esperada de la respuesta dado el conocimiento que se tenga de la intervención.
- La serie de tiempo libre de intervenciones es llamada *serie de ruido* y es denotada por N_t . De acuerdo con el modelo general anterior $N_t = \frac{\theta(B)}{\Psi(B)} a_t$
- Para identificar el modelo para N_t , se usan los datos de la serie antes de la intervención. Otra alternativa en Castaño (1995, 1997, 2008).
- Si los diagnósticos sobre el modelo no revelan violaciones a los supuestos, el modelo estimado puede ser empleado para hacer inferencias sobre la intervención (y pronósticos). En otro caso, se deben hacer las modificaciones apropiadas sobre el modelo y repetir los diagnósticos.

EJEMPLO: Considere la siguiente serie de tiempo. Número de observaciones 500.

Sabemos que existe una intervención en el período $t=350$ cuyo efecto es elevar en una cantidad fija el nivel de la serie a partir de ese período.



Modelo de intervención postulado:

$$Z_t = wB^b S_t(T) + \frac{\theta(B)}{\psi(B)} a_t$$

Con $T=350$ y $b=0$ (no hay rezago en el efecto de la intervención, es decir, la intervención afecta a la serie desde el momento en que ella ocurre).

Procedimiento de identificación del modelo del ruido y estimación de la serie intervenida:

1. Identificación del modelo del ruido: Para los primeros 349 datos (donde no ha ocurrido todavía la intervención) utilizamos el procedimiento de identificación de un modelo ARIMA antes visto.

Se encontró que la transformación estabilizadora de varianza es $\lambda=1$: No hay necesidad de transformar los datos. Su varianza parece estable.

ACF y PACF MUESTRAL PARA $n=349$ observaciones

- SERIE ORIGINAL

NAME OF THE SERIES	Z
TIME PERIOD ANALYZED	1 TO 349
MEAN OF THE (DIFFERENCED) SERIES . . .	33.2710
STANDARD DEVIATION OF THE SERIES . . .	18.2366
T-VALUE OF MEAN (AGAINST ZERO)	34.0828

AUTOCORRELATIONS

		-1.0	-0.8	-0.6	-0.4	-0.2	0.0	0.2	0.4	0.6	0.8	1.0
		+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+										
1	0.99						+	IXX+XXXXXXXXXXXXXXXXXXXXXXX				
2	0.98						+	IXXXX+XXXXXXXXXXXXXXXXXXXXX				
3	0.96						+	IXXXX+XXXXXXXXXXXXXXXXXXXXX				
4	0.95						+	IXXXX+XXXXXXXXXXXXXXXXXXXXX				
5	0.94						+	IXXXX+XXXXXXXXXXXXXXXXXXXXX				
6	0.93						+	IXXXX+XXXXXXXXXXXXXXXXXXXXX				
7	0.92						+	IXXXX+XXXXXXXXXXXXXXXXXXXXX				
8	0.91						+	IXXXX+XXXXXXXXXXXXXXXXXXXXX				
9	0.90						+	IXXXX+XXXXXXXXXXXXXXXXXXXXX				
10	0.89						+	IXXXX+XXXXXXXXXXXXXXXXXXXXX				
11	0.88						+	IXXXX+XXXXXXXXXXXXXXXXXXXXX				
12	0.87						+	IXXXX+XXXXXXXXXXXXXXXXXXXXX				
13	0.86						+	IXXXX+XXXXXXXXXXXXXXXXXXXXX				
14	0.85						+	IXXXX+XXXXXXXXXXXXXXXXXXXXX				
15	0.84						+	IXXXX+XXXXXXXXXXXXXXXXXXXXX				
16	0.83						+	IXXXX+XXXXXXXXXXXXXXXXXXXXX				
17	0.82						+	IXXXX+XXXXXXXXXXXXXXXXXXXXX				
18	0.81						+	IXXXX+XXXXXXXXXXXXXXXXXXXXX				
19	0.81						+	IXXXX+XXXXXXXXXXXXXXXXXXXXX				
20	0.80						+	IXXXX+XXXXXXXXXXXXXXXXXXXXX				

PARTIAL AUTOCORRELATIONS

		-1.0	-0.8	-0.6	-0.4	-0.2	0.0	0.2	0.4	0.6	0.8	1.0
		+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+										
							I					
1	0.99						+	IXX+XXXXXXXXXXXXXXXXXXXXXXX				
2	0.02						+	IX +				
3	0.01						+	I +				
4	-0.02						+	XI +				
5	0.01						+	I +				
6	0.00						+	I +				
7	-0.01						+	I +				
8	0.03						+	IX +				
9	0.01						+	I +				
10	0.00						+	I +				
11	0.04						+	IX +				
12	-0.01						+	I +				
13	-0.05						+	XI +				
14	0.00						+	I +				
15	0.02						+	IX +				
16	-0.01						+	I +				
17	0.01						+	I +				
18	-0.01						+	I +				
19	0.02						+	IX +				
20	-0.02						+	I +				

Los resultados indican que la serie parece tener componentes de tendencia y por tanto no es estacionaria (Aplicar prueba de raíz unitaria).

- SERIE DIFERENCIADA 1 VEZ

DIFFERENCE ORDERS. (1-B)
 NAME OF THE SERIES Z
 TIME PERIOD ANALYZED 1 TO 349
 MEAN OF THE (DIFFERENCED) SERIES . . . 0.2022
 STANDARD DEVIATION OF THE SERIES . . . 1.0025
 T-VALUE OF MEAN (AGAINST ZERO) 3.7617

AUTOCORRELATIONS

	-1.0	-0.8	-0.6	-0.4	-0.2	0.0	0.2	0.4	0.6	0.8	1.0
	+-----+-----+-----+-----+-----+-----+-----+-----+-----+										
	I										
1	-0.23					XXX+XXI	+				
2	0.01					+	I	+			
3	0.00					+	I	+			
4	0.08					+	IXX	+			
5	-0.06					+	XI	+			
6	0.01					+	I	+			
7	0.05					+	IX	+			
8	0.02					+	IX	+			
9	-0.03					+	XI	+			
10	0.00					+	I	+			
11	-0.02					+	XI	+			
12	0.06					+	IX	+			
13	-0.03					+	XI	+			
14	-0.05					+	XI	+			
15	-0.02					+	I	+			
16	0.01					+	I	+			
17	0.04					+	IX	+			
18	-0.10					+	XXI	+			
19	0.04					+	IX	+			
20	0.03					+	IX	+			

PARTIAL AUTOCORRELATIONS

	-1.0	-0.8	-0.6	-0.4	-0.2	0.0	0.2	0.4	0.6	0.8	1.0
	+-----+-----+-----+-----+-----+-----+-----+-----+-----+										
	I										
1	-0.23					XXX+XXI	+				
2	-0.18					X+XXI	+				
3	-0.10					+	XXI	+			
4	0.08					+	IXX	+			
5	-0.02					+	XI	+			
6	-0.01					+	I	+			
7	0.05					+	IX	+			
8	0.05					+	IX	+			
9	-0.01					+	I	+			
10	-0.02					+	I	+			
11	-0.04					+	XI	+			
12	0.05					+	IX	+			
13	0.00					+	I	+			
14	-0.07					+	XXI	+			
15	-0.06					+	XI	+			
16	-0.02					+	I	+			
17	0.06					+	IX	+			

18	-0.07	+XXI	+
19	0.00	+ I	+
20	0.03	+ IX	+

Parece que la serie se estacionariza con una diferencia. El contraste t para la inclusión de una componente de tendencia determinística, indica la necesidad de incluirla ($t=3.7617$).

IDENTIFICACIÓN DE LOS ÓRDENES DE p Y q.

La ACF y PACF muestrales anteriores para la primera diferencia, indican un corte después del primer rezago en la ACF, y la PACF parece extinguirse exponencialmente. Concluimos que un modelo ARIMA(0,1,1) parece consistente con los datos de la serie no intervenida.

MODELO TENTATIVO:

$$(1-B)Z_t = \theta_0 + wB^b (1-B)S_t(350) + (1-\theta_1 B)a_t$$

ESTIMACIÓN:

IIINSTRUCCIONES PARA EL SCA:

GENERATE VAR S350. NROWS 500. VALUES 0 FOR 349 1 FOR 200.

TSMODEL MODINTER. MODEL Z(1)=CONST+(W)S350(1,BIN)+(1-THETA1*B)NOISE.

ESTIM MODINTER.

ESTIM MODINTER. METHOD EXACT. HOLD RESIDUALS(RES) FITTED(AJUST).

RESULTADOS DE LA ESTIMACIÓN:

THE FOLLOWING ANALYSIS IS BASED ON TIME SPAN 1 THRU 500

NONLINEAR ESTIMATION TERMINATED DUE TO:
RELATIVE CHANGE IN THE STANDARD ERROR LESS THAN 0.1000D-02

SUMMARY FOR UNIVARIATE TIME SERIES MODEL -- MODARMA2

VARIABLE	TYPE OF VARIABLE	ORIGINAL OR CENTERED	DIFFERENCING
Z	RANDOM	ORIGINAL	1 (1-B)

S350	BINARY	ORIGINAL	1 (1-B)					
PARAMETER LABEL	VARIABLE NAME	NUM./ DENOM.	FACTOR	ORDER	CONS- TRAIT	VALUE	STD ERROR	T VALUE
1	CONST2	CNST	1	0	NONE	.1809	.0326	5.55
2	W	S350 NUM.	1	0	NONE	9.7371	.9162	10.63
3	MA1	Z MA	1	1	NONE	.2271	.0436	5.21

EFFECTIVE NUMBER OF OBSERVATIONS 499
R-SQUARE 0.999
RESIDUAL STANDARD ERROR. 0.939026E+00

DIAGNÓSTICOS:

- Dado que $|MA1|=0.2271 < 1$, el modelo es invertible

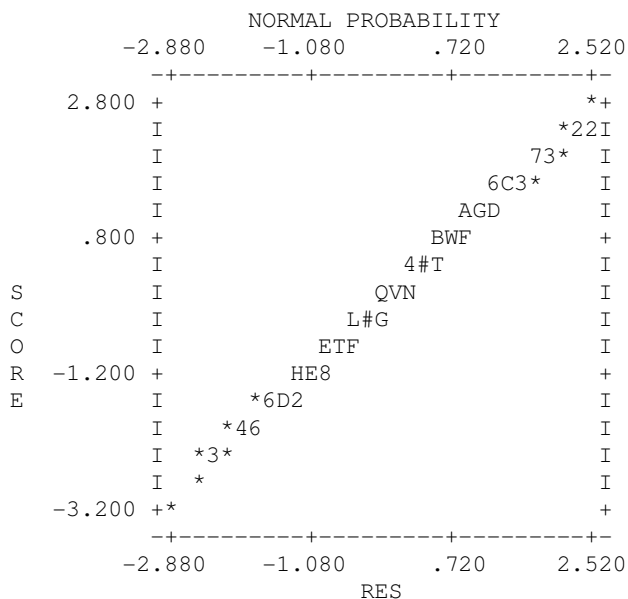
- ACF muestral de los residuales

NAME OF THE SERIES RES
TIME PERIOD ANALYZED 2 TO 500
MEAN OF THE (DIFFERENCED) SERIES 0.0002
STANDARD DEVIATION OF THE SERIES 0.9390
T-VALUE OF MEAN (AGAINST ZERO) 0.0038

		AUTOCORRELATIONS										
		-1.0	-0.8	-0.6	-0.4	-0.2	0.0	0.2	0.4	0.6	0.8	1.0
		+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+										
		I										
1	0.00	+ I +										
2	0.01	+ I +										
3	0.01	+ I +										
4	0.08	+ IX+										
5	-0.02	+XI +										
6	-0.02	+XI +										
7	0.05	+ IX+										
8	0.01	+ I +										
9	-0.02	+ I +										
10	-0.03	+XI +										
11	-0.04	+XI +										
12	0.06	+ IX+										
13	-0.02	+XI +										
14	-0.05	+XI +										
15	-0.03	+XI +										
16	-0.02	+XI +										
17	0.01	+ I +										
18	-0.07	XXI +										
19	0.00	+ I +										
20	0.05	+ IX+										

EL ACF parece consistente con un proceso de ruido blanco

- Normalidad del proceso del ruido



De los resultados anteriores no rechazamos el supuesto de normalidad

CONCLUSIÓN: El modelo parece adecuado. Por tanto, los resultados muestran que el efecto de la intervención es elevar en aproximadamente 10 unidades el nivel de la serie a partir del período 350.

Análisis de Observaciones atípicas (Outliers)

- Las series de tiempo están frecuentemente afectadas por eventos tales como días de fiesta, huelgas, promociones, apagones, otros cambios de política. En otros casos se presentan mediciones erróneas o registros erróneos.
- Cuando el período de ocurrencia de estos eventos externos (exógenos) es desconocido, a las observaciones generadas por ellos se les llama observaciones atípicas (Outliers).

- Debido a que la presencia de observaciones atípicas afectan la inferencia resultante haciéndola poco confiable o aún inválida, es importante tener procedimientos que permitan **su detección y la remoción de sus efectos**.
- El SCA cuenta con dos procedimientos para la detección y corrección de la observaciones atípicas: el de Chang, Tiao y Chen (1988) y el de Chen y Liu (1990).

Procedimiento de Chang, Tiao y Chen (1988): En este procedimiento:

- ✓ Se identifica primero un modelo ARIMA y se estima asumiendo que no hay observaciones atípicas.
- ✓ El procedimiento de detección de outliers se aplica a la serie de residuales para verificar si están presentes.
- ✓ Si es así, se estima un modelo ajustado, el cual incluye los efectos de los outliers como intervenciones.
- ✓ La detección y el ajuste continúa en la medida que sea necesario, después que el modelo intervenido es estimado.

Este procedimiento usa el análisis de intervención y está implementado en el comando OUTLIER del SCA.

Procedimiento de Chen y Liu (1990):

El procedimiento anterior propuesto por Chang, Tiao y Chen es útil en cierta medida. Sin embargo, tiene algunas deficiencias:

- Si el modelo inicial está mal identificado, pueden aparecer observaciones atípicas.

- La eficiencia del procedimiento de detección de outliers puede estar afectada por los sesgos en los parámetros debido a la presencia de outliers.
- Algunos outliers pueden estar enmascarados y no ser identificados.
- Se pueden detectar algunos outliers espúreos (falsos).

Para evitar los problemas anteriores, Chen, Liu y Hudak (1990) Chen y Liu (1993), proponen un procedimiento iterativo para la estimación conjunta de los parámetros del modelo y de los efectos de los outliers.

El procedimiento es:

- ✓ Se inicia como antes, con un modelo identificado y con estimadores potencialmente sesgados, debido a la presencia de outliers.
- ✓ A continuación, a los residuales del modelo estimado se aplica un procedimiento iterativo de detección de outliers.
- ✓ A continuación la serie original es ajustada (para remover los efectos de los outliers) de acuerdo a los tipos de outliers detectados.
- ✓ Después se estima el modelo para la serie ajustada y se examinan los residuales de nuevo. Los tres pasos de
 - 1) detección de outliers,
 - 2) ajuste de la serie por los efectos de los outliers, y
 - 3) estimación de los parámetros de la serie ajustada, son iterados hasta que no se encuentren más outliers.
- ✓ En este momento, la información acumulada de los outliers es empleada para estimar conjuntamente los efectos de los outliers y producir una serie final de observaciones ajustadas.

- ✓ Después de este paso, se estima el modelo con la serie ajustada para obtener las estimaciones finales de los parámetros.
- ✓ Finalmente, el procedimiento de detección de outliers es aplicado a la serie de residuales de la serie original usando las estimaciones finales de los parámetros del modelo.

Este procedimiento difiere del anterior en varios aspectos. Primero, la detección de outliers se hace iterativamente basada tanto en los residuales ajustados como en las observaciones ajustadas. Es decir, una vez una observación atípica es detectada, su efecto puede ser removido de la serie observada de la misma forma que puede ser removido de los residuales del modelo estimado. Al ajustar la serie observada, este procedimiento evita la necesidad de formular y estimar un modelo de intervención. Segundo, los outliers son detectados basados en estimadores robustos de los parámetros del modelo. Finalmente, en este procedimiento, los efectos de los outliers son estimados conjuntamente usando regresión múltiple. Como resultado, este procedimiento produce estimaciones más robustas de los parámetros del modelo, y reduce los outliers espúreos y el efecto de enmascaramiento en el proceso de detección.

Este procedimiento está implementado en el comando OESTIM del SCA.

Tipos de outliers que detecta el SCA:

- Observación atípica Aditiva (AO): Es un evento que afecta a una serie de tiempo solamente durante un período. Si suponemos que el outlier ocurre en el momento $t=T$, la serie observada se puede representar como:

$$Y_t = Z_t + W_A P_t(T)$$

- Observación atípica Innovativa (IO): Es un evento cuyo efecto es propagado de acuerdo al modelo ARIMA del proceso. Si suponemos que

el outlier ocurre en el momento $t=T$, la serie observada se puede representar como:

$$Y_t = Z_t + \frac{\theta(B)}{\phi(B)} W_I P_t(T)$$

donde $Z_t = \frac{\theta(B)}{\phi(B)} a_t$

- Observación atípica de cambio de nivel (LS): Es un evento que afecta permanentemente la serie a partir de un período dado. Si suponemos que el outlier ocurre en el momento $t=T$, la serie observada se puede representar como:

$$Y_t = Z_t + \frac{1}{1-B} W_L P_t(T), \text{ usando la variable de pulso } P_t(T),$$

o,

$$Y_t = Z_t + W_L S_t(T), \text{ usando la variable de salto } S_t(T),$$

- Observación atípica de cambio temporal (TC): Es un evento que impacta inicialmente la serie y luego desaparece gradualmente. Si suponemos que el outlier ocurre en el momento $t=T$, la serie observada se puede representar como:

$$Y_t = Z_t + \frac{1}{1-\delta B} W_C P_t(T), \quad 0 < \delta < 1$$

Ejemplo. Suponga que en ejemplo anterior no sabemos que existió un evento exógeno que impactó la serie desde la observación 350, ni conocemos su forma más probable. Si esto fuera así, podemos usar el SCA para detectar tanto el período de ocurrencia, como la forma de impacto del outlier.

```

tsmodel modarma3. model z(1)=const2+(1-ma12*b)noise.

oestim modarma3. method exact. hold residuals(res) fitted(ajust). @
    type ao io ls tc. ostop critical(3.5).

THE FOLLOWING ANALYSIS IS BASED ON TIME SPAN   1   THRU   500
SUMMARY FOR UNIVARIATE TIME SERIES MODEL -- MODARMA3
-----
VARIABLE   TYPE OF   ORIGINAL   DIFFERENCING
          VARIABLE OR CENTERED

              1
          Z      RANDOM   ORIGINAL   (1-B )
-----
PARAMETER  VARIABLE  NUM./  FACTOR  ORDER  CONS-   VALUE   STD   T
  LABEL      NAME    DENOM.          TRAJNT   ERROR  VALUE

  1  CONST2                CNST      1      0    NONE    .1847   .0327   5.65
  2  MA12      Z         MA        1      1    NONE    .2231   .0437   5.10

SUMMARY OF OUTLIER DETECTION AND ADJUSTMENT
-----
TIME      ESTIMATE   T-VALUE   TYPE
-----
  350      10.092     10.75     LS
-----

TOTAL NUMBER OF OBSERVATIONS. . . . . 500
EFFECTIVE NUMBER OF OBSERVATIONS. . . . . 499
RESIDUAL STANDARD ERROR (WITHOUT OUTLIER ADJUSTMENT). . . 0.104108E+01
RESIDUAL STANDARD ERROR (WITH OUTLIER ADJUSTMENT) . . . 0.938662E+00

```

Los resultados muestran que se detectó una observación de cambio de nivel en el período 350 y se ajustó la serie teniéndolo en cuenta.

OTRA FORMA: USANDO el parágrafo OUTLIER

```

tsmodel modarma4. model z(1)=const2+(1-ma12*b)noise.
estim modarma4. method exact. hold residuals(res) fitted(ajust).

THE FOLLOWING ANALYSIS IS BASED ON TIME SPAN   1   THRU   500

```


NONLINEAR ESTIMATION TERMINATED DUE TO:
 RELATIVE CHANGE IN THE STANDARD ERROR LESS THAN 0.1000D-02
 SUMMARY FOR UNIVARIATE TIME SERIES MODEL -- MODARMA4

```
-----
VARIABLE   TYPE OF   ORIGINAL   DIFFERENCING
          VARIABLE OR CENTERED

          Z      RANDOM   ORIGINAL   (1-B1)
-----
PARAMETER  VARIABLE  NUM./    FACTOR  ORDER  CONS-    VALUE    STD     T
          LABEL    NAME    DENOM.              TRAJNT   ERROR   VALUE

1  CONST2                CNST     1      0     NONE     .2000    .0362   5.53
2  MA12      Z          MA       1      1     NONE     .2130    .0435   4.89
```

EFFECTIVE NUMBER OF OBSERVATIONS 499
 R-SQUARE 0.999
 RESIDUAL STANDARD ERROR. 0.103980E+01

--

outlier modarma4. stop critical(3.5). type ao io ls tc.

INITIAL RESIDUAL STANDARD ERROR = 1.0398

TIME	ESTIMATE	T-VALUE	TYPE
350	10.07	10.74	LS

ADJUSTED RESIDUAL STANDARD ERROR = 0.93671

Como antes, el procedimiento detecta un outlier de cambio de nivel. En este caso el outlier debe ser modelado como una intervención sobre la serie, como se vio en la sección anterior de análisis de Intervención.

El Efecto de las observaciones atípicas sobre la función de autocorrelación muestral

Es bien conocido que las observaciones atípicas pueden influenciar fuertemente la ACF muestral y por tanto afectar la identificación de los modelos de series de tiempo. Chan (1985), muestra que los distintos tipos de observaciones atípicas pueden tener efectos cualitativamente diferentes. Sus resultados indican que en muestras grandes la ACF muestral puede resultar seriamente afectada ante la existencia de observaciones atípicas AO, LS o TC.

- i) Una observación atípica aditiva (AO) grande puede anular completamente la información de la ACF muestral.
- ii) Cuando $T \gg K$, siendo T el período de ocurrencia de la observación atípica y k el orden del coeficiente de autocorrelación muestral, una observación atípica de cambio de nivel (LS) empuja la ACF muestral hacia 1, la cual es la cota no estacionaria de la función de autocorrelación. La ACF muestral decae lentamente a medida que k crece. Este resultado coincide con el obtenido por Chang (1982).
- iii) Para el caso de una observación atípica de cambio temporal (TC), los valores de la ACF muestral son dominados por el factor de decaimiento δ .
- iv) Finalmente, la existencia de una observación atípica innovativa (IO), no altera el cálculo de la ACF muestral puesto ella tiende a ρ_k cuando n y W_1 son grandes.

Observación: El programa computacional TRAMO (Time series Regression with ARIMA noise, Missing observations and Outliers) desarrollado por Victor Gómez and Agustín Maravall es un programa para estimar y pronosticar modelos de regresión con posibles términos de error ARIMA y observaciones faltantes. El programa también identifica y corrige varios tipos de observaciones atípicas y estima efectos calendario tales como el efecto Día Comercial, Semana Santa y efectos generales de intervención. Este programa es de uso libre y se encuentra implementado bajo Windows y en varios paquetes econométricos como el GRET, el cual también es de uso libre.

Lecturas:

- Box, G.E.P., and Tiao, G. (1975). "Intervention Analysis with Applications to Economic and Environmental Problems," Journal of the American Statistical Association, Vol 70, pp. 70-79.
- W-S, Chan (1995) "Understanding the Effect of Time Series Outliers on Sample Autocorrelations", *Test*, Vol. 4, No. 1, pp. 179-186.
- Chen, C., and L. M. Liu, (1993), "Joint Estimation of Model Parameters and Outlier Effects in Time Series," *JASA*, 88, p.276-289.

- Chen, Liu y Hudak (1990) "Outlier Detection and Adjustment in Time Series Modeling and Forecasting", Working paper, SCA.
- Wei (1990) "Time Series análisis". Capítulo 9.
- Guerrero (2003) "Análisis Estadístico de Series de tiempo Económicas", Capítulo 7.
- Castaño (1997) "Identificación de un modelos ARIMA contaminados", Lecturas de Economía, Vol. 47.
- Castaño (2008) "Reconstrucción de datos de series de tiempo: una aplicación a la demanda horaria de la electricidad", Revista Colombiana de Estadística Volumen 30 No. 2. pp. 247 a 263.